PROYECTO FINAL · CIENCIA DE DATOS, SECCIÓN A · UFM

¿Va a dejar de pagar este cliente el mes que viene?

Un modelo de riesgo de impago para decidir si el banco mantiene, revisa o reduce la línea de crédito.

George Albadr · Milton Beltrán · noviembre de 2026

El modelo no predice por predecir: elige una de tres acciones

$p < 0.12$

Mantener

La línea sigue igual.

$0.12 \leq p < 0.35$

Revisar

Un analista mira el caso.

$p \geq 0.35$

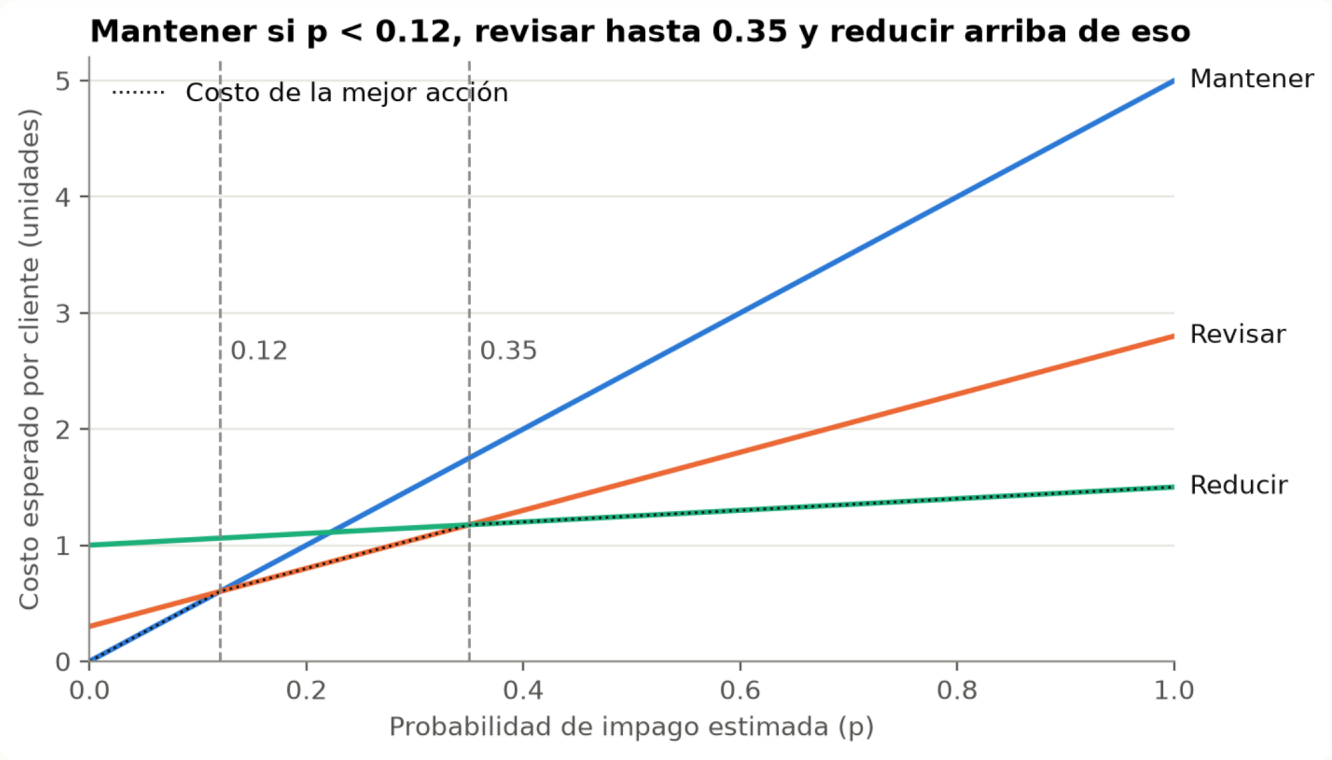
Reducir

Se baja el límite. Una persona firma.

Métrica: costo promedio por cliente. La exactitud no sirve: con 22 % de impago, decir «nadie impaga» acierta 78 % y no le ahorra nada al banco.

p = probabilidad de impago del mes siguiente que estima el modelo · Notebook 01, sección 1

Los costos de cada error fijan los umbrales antes de ver los datos



Supuesto	Valor
Impago no detectado	5
Reducir a quien paga	1
Revisar un caso	0.3
Impagos que detecta el analista	50 %
Pérdida que queda al reducir	30 %

Son supuestos nuestros, no cifras del banco. Sin modelo, lo mejor es revisar a todos: **0.853 por cliente**. Esa es la vara.

Unidades relativas: 1 = reducirle el límite a un cliente que sí iba a pagar · src/costos.py · Notebook 01, sección 1

30,000 clientes reales, y la prueba guardada desde el primer día

30,000

clientes de un banco de Taiwán, abril a septiembre de 2005. UCI, licencia CC BY 4.0.

22.1 %

impagó en octubre. Igual en entrenamiento y en prueba.

24k / 6k

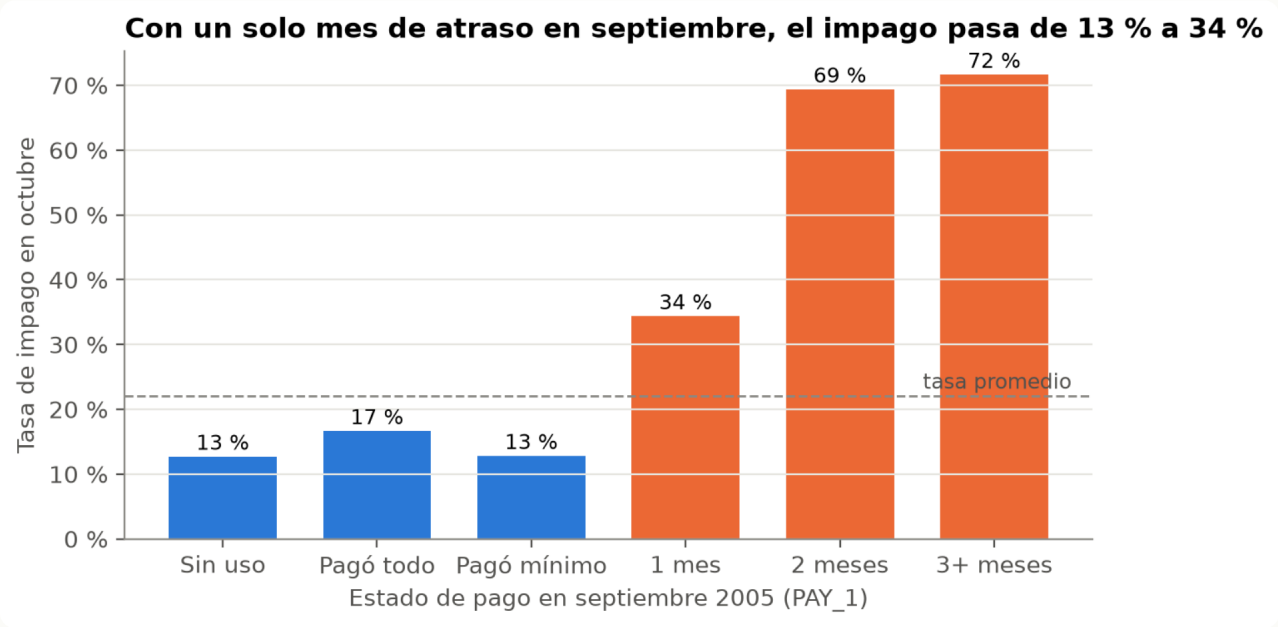
entrenamiento y prueba, estratificado, antes del EDA. La prueba se abrió una vez.

Limpieza documentada

- Códigos sin documentar (educación 0, 5, 6 y estado civil 0) pasan a «Otros»: 399 clientes.
- 35 filas idénticas salvo el ID se conservan: son clientes distintos, casi todos cuentas sin movimiento.
- Montos extremos no se recortan: son colas largas reales, no errores.

src/datos.py · Notebook 01, secciones 2 a 4 · Bitácora, entradas 1 a 4

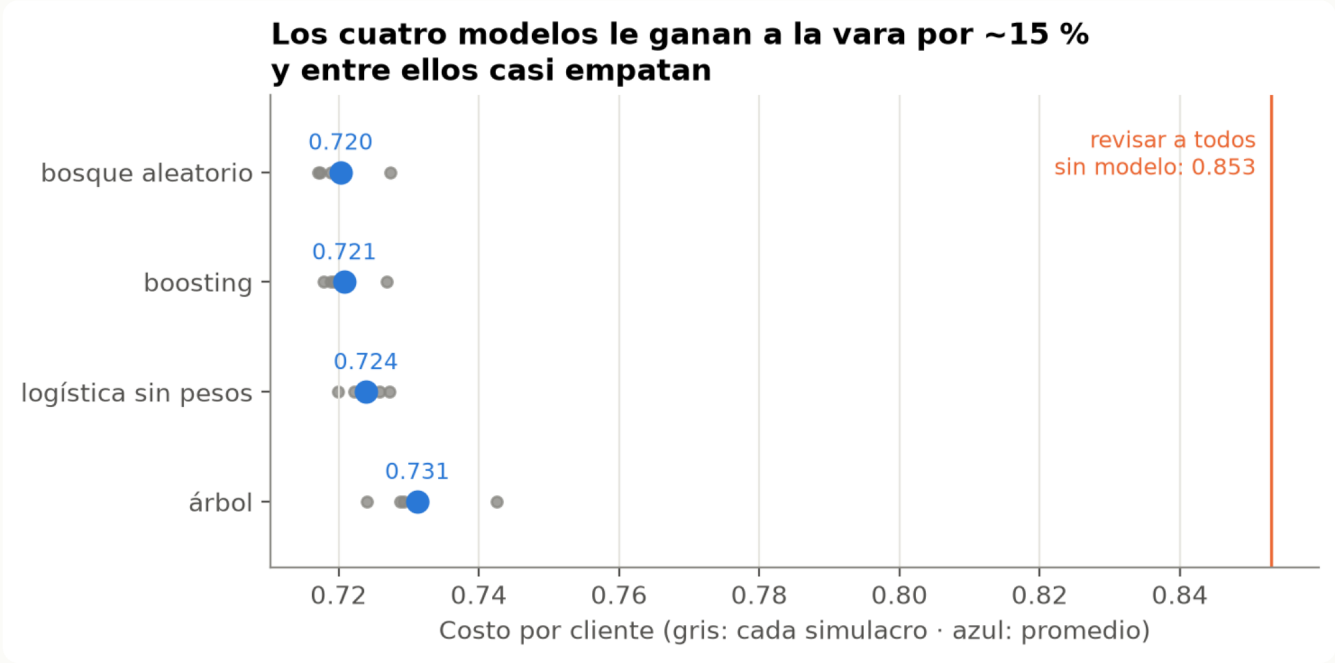
El historial de pagos domina la señal, y eso guió el modelo



Hallazgo	Decisión
Un mes de atraso en septiembre sube el impago de 13 % a 34 %	Variables: meses con atraso y atraso reciente
Uso de la línea en U; cuentas sin movimiento impagan ~37 %	Variables: uso de la línea e inactiva
Sexo y estado civil separan poco	Probar el modelo sin ellas
Montos con colas largas; facturas de meses seguidos casi iguales	Logaritmo y regularización

Solo datos de entrenamiento (24,000) · Notebook 01, secciones 5 y 6 (13 hallazgos con su decisión)

Cuatro modelos le ganan a la vara por ~15 % y entre ellos casi empatan



Elegimos la logística

- Pierde 0.003 por cliente contra el boosting: 0.4 % del costo.
- El banco puede explicarle a un cliente por qué le baja el límite.
- Sus probabilidades ya dicen la verdad, sin pasos extra.

El boosting ganó en las 5 rondas: la diferencia es real pero chica. Es el precio que aceptamos.

Mismos 5 simulacros estratificados para todos; perillas elegidas por costo con GridSearchCV · Notebook 02, secciones 2 a 7

Cada perilla se decidió con cinco simulacros sobre el costo

Atrasos como categoría

El costo baja de 0.760 a 0.727. Cada código recibe su propio peso.

Sin pesos por clase

Con pesos, la probabilidad media sube de 0.22 a 0.43 y el costo a 0.868: peor que no tener modelo.

Sin sexo ni estado civil

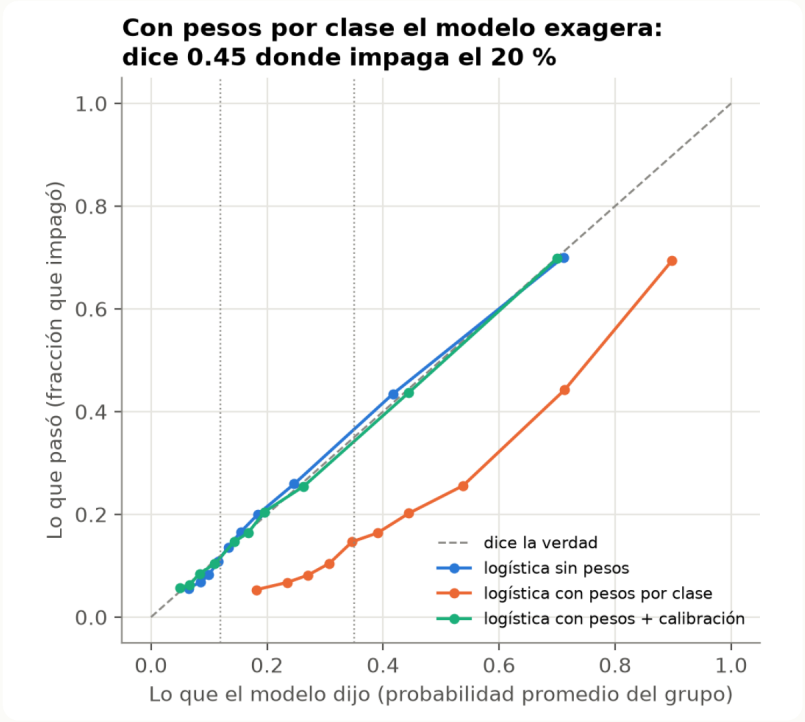
Quitarlas sube el costo 0.0015 (0.2 %). Usarlas tiene un costo ético y legal.

Regularización C = 0.03

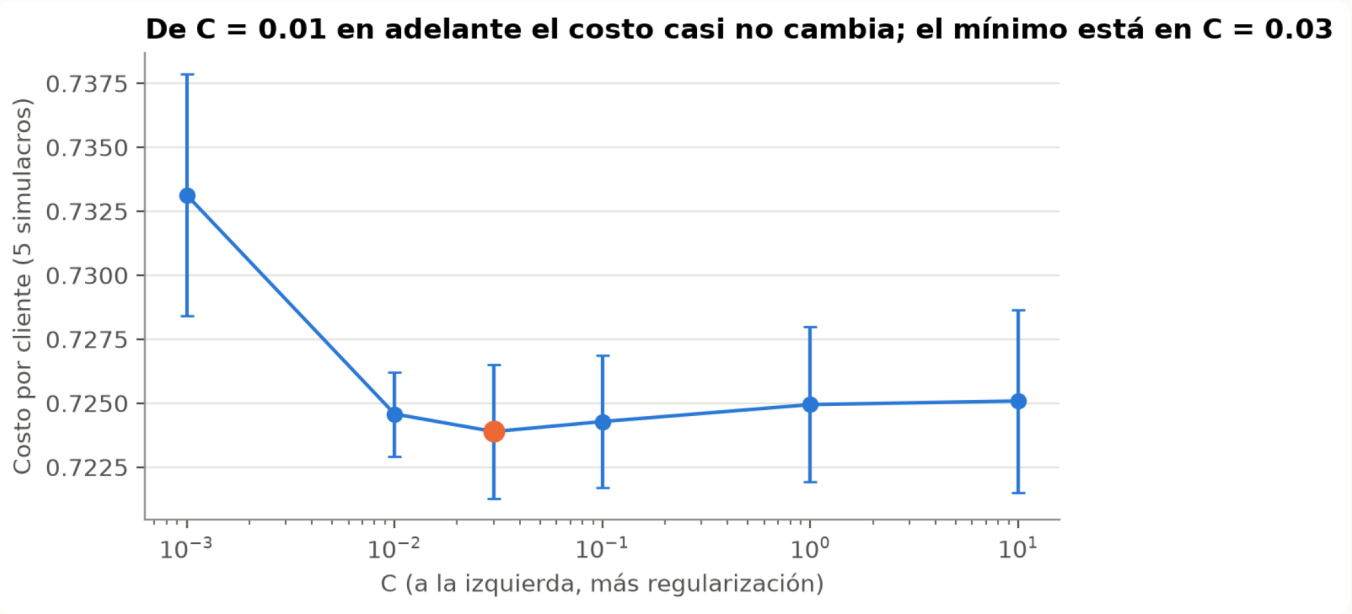
Se probó 0.001, 0.01, 0.03, 0.1, 1 y 10. De 0.01 a 10 el costo casi no cambia.

Todo lo que aprende de los datos va dentro de un Pipeline · Notebook 02, secciones 2, 3, 4, 8 y 9

Con pesos por clase el modelo exagera; C casi no importa



Con pesos por clase, la probabilidad media sube a 0.43 y el costo a **0.868**, peor que la vara (0.853). Sin pesos, la logística ya dice la verdad.



C se probó en **0.001, 0.01, 0.03, 0.1, 1 y 10**, cada uno con 5 simulacros. El mínimo está en 0.03 (0.724). De 0.01 a 10 la diferencia es menor que la variación entre rondas; solo 0.001 es claramente peor (0.733).

Simulacros de entrenamiento · Notebook 02, secciones 3 y 4 (figuras f9 y f10)

LA PRUEBA, ABIERTA UNA SOLA VEZ · 6,000 CLIENTES NUEVOS

0.740

por cliente con el modelo

0.853

revisando a todos, sin modelo

13.3 % de ahorro · IC 95 %: 11.5 % a 15.1 %

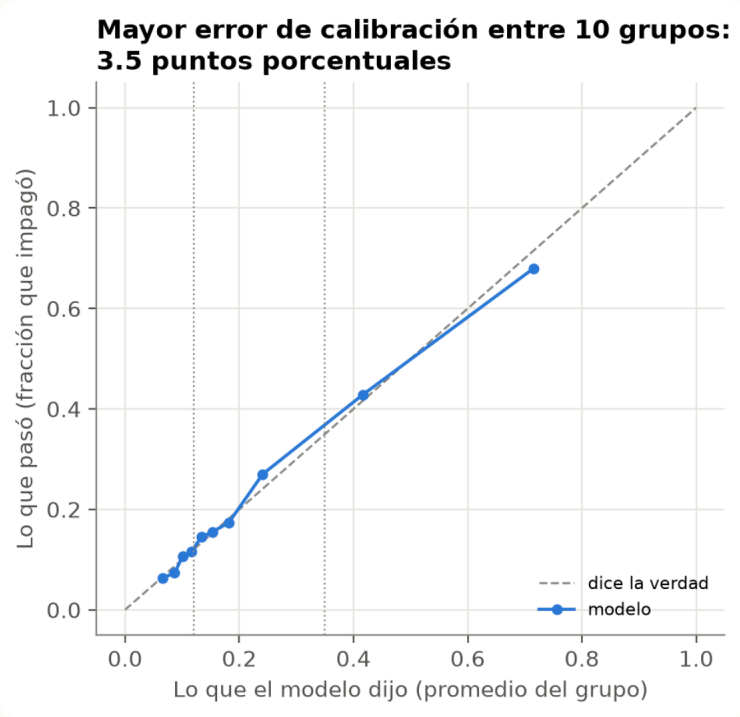
Los simulacros decían 0.725: cae dentro del intervalo del costo en la prueba (0.712 a 0.767). Reportamos 0.740.

Bootstrap de 2,000 remuestreos · AUC 0.765 · probabilidad media 0.221 = tasa real · Notebook 03, sección 2

En la prueba, el riesgo sube como debe de una acción a otra

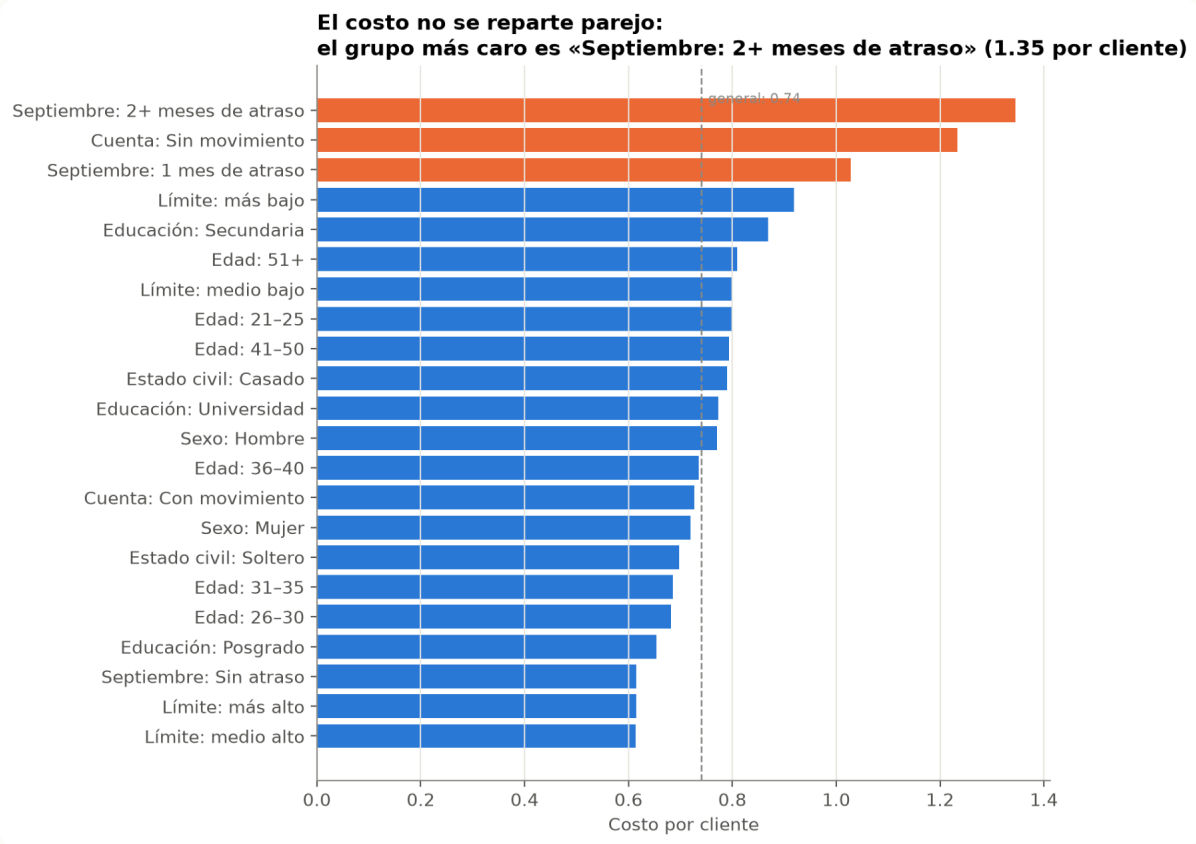
Acción	Clientes	Impagó	% del costo
Mantener	2,206	8.7 %	21.6 %
Revisar	2,724	18.8 %	47.2 %
Reducir	1,070	58.2 %	31.1 %

- Revisar o reducir atrapa al **86 %** de los impagos, con precisión 0.30.
- Solo reducir atrapa al 47 %, con precisión 0.58.
- Calibración: el error más grande entre 10 grupos es de 3.5 puntos.



Matriz de confusión de 3 acciones × 2 resultados · Notebook 03, secciones 3 y 4

Dónde falla: impagos que parecen buenos pagadores



192 de 1,327 impagos se escapan

14.5 %. Casi ninguno tenía atraso en septiembre y su límite mediano es 220,000 (80,000 en los alertados). Con estas columnas no se distinguen.

447 de 4,673 buenos pagadores pierden límite

9.6 %. Más en hombres (10.9 % contra 8.7 %) y en las edades extremas: 21 a 25 y 51 o más.

El modelo no usa sexo ni estado civil; se usan aquí solo para revisar el trato por grupo · Notebook 03, sección 5

Si nuestros costos están mal, el modelo igual le gana a la vara

Impago : castigo	Umbrales	Ahorro	A revisión
2 : 1	0.30 / 0.50	17.6 %	8.3 %
3 : 1	0.20 / 0.44	20.1 %	16.7 %
5 : 1 (nuestro)	0.12 / 0.35	13.3 %	45.4 %
8 : 1	0.075 / 0.27	12.9 %	70.1 %
10 : 1	0.06 / 0.23	14.0 %	72.1 %

El cuello de botella es la revisión

Con 5 : 1 va a un analista el 45 % de los clientes. Si el banco sube el primer umbral a 0.20, revisa el 12.5 % y cuesta 0.769, todavía bajo la vara. Pero los impagos que se escapan suben de 14.5 % a 37.5 %.

Esa decisión es del banco.

Mismo modelo y mismas probabilidades; cambian solo los umbrales · Análisis de sensibilidad, no una nueva elección · Notebook 03, secciones 5.3 y 5.4

Cada mes el modelo recomienda; una persona decide

Cómo se usaría

1. Al cerrar la facturación, el modelo da una probabilidad por cliente.
2. Los umbrales la vuelven mantener, revisar o reducir.
3. La cola de revisión va de mayor a menor riesgo.
4. Reducir es una recomendación con su explicación; la firma una persona.

Antes: dos meses en sombra. Después: un grupo de control sin intervenir.

Se monitorea	Señal de alarma
Calibración	Probabilidad media lejos del impago real
Clientes	Atrasos o uso de la línea cambian de golpe
Carga de revisión	Más casos de los que el equipo revisa
Costo real	Se acerca a la vara
Trato por grupo	Brechas por sexo o edad que crecen
Supuestos	El analista detecta lejos del 50 %

Reentrenar cuando se rompa la calibración, o al menos una vez al año · Notebook 03, sección 7

Lo que este trabajo no permite concluir

No vale para otro banco ni para hoy

Son clientes de Taiwán en 2005, y se predice un solo mes.

El ahorro no es dinero

Está en unidades de cinco supuestos nuestros.

Predecir no es intervenir

No sabemos si reducir el límite evita la pérdida o la empeora.

Los pesos no son causas

Un atraso se asocia con el impago; no probamos que lo provoque.

No garantiza un trato justo

La edad sigue en el modelo. Medimos brechas; no las corregimos.

Solo clientes con tarjeta

No dice a quién darle una tarjeta nueva.

Lista completa (9 puntos) en el notebook 03, sección 8

La AI propuso opciones; nosotros verificamos y descartamos

Se preguntó	Se verificó	Se descartó
¿Borrar 35 filas repetidas?	Son clientes distintos, casi todos sin movimiento	Borrarlas: sesgaría contra esas cuentas
¿Pesos por clase por el desbalance?	Inflan la probabilidad a 0.43 y el costo a 0.868	Pesos y calibración: mismo resultado, más pasos
¿Logística o ensambles?	El boosting gana por 0.4 %, menos que el ruido de la prueba	Boosting y bosque, por explicabilidad
¿Cómo abrir la prueba una sola vez?	0.725 de los simulacros cae en el IC de la prueba	Ajustar algo después de ver la prueba

La bitácora completa tiene 8 entradas con lo que se preguntó, se usó, se verificó y se descartó.