Universidad Francisco Marroquín
Catedrático:Enrique Bolaños
Aux: Abner Josué Miguel Xocop Chacach
Materia: Ciencia de Datos, Sección A
Integrantes: George Albadr, Milton Beltrán y un tercer integrante por confirmar

Propuesta de Proyecto Final — Riesgo de Impago de Tarjetas de Crédito

1. PROBLEMA Y A QUIÉN LE IMPORTA

Un banco que emite tarjetas de crédito tiene que decidir a qué clientes les mantiene la línea y en cuáles ve un riesgo de impago. La decisión pesa sobre todo en el analista de crédito y en el área de riesgos, porque cada cliente que cae en mora es una pérdida directa. Pesa también en el cliente que sí paga, a quien un rechazo injusto deja sin crédito.

2. LA DECISIÓN

Predecimos si un cliente caerá en impago el mes siguiente para decidir si se mantiene su límite, se reduce o pasa a revisión manual. Los dos errores no cuestan lo mismo. Aprobar a quien después no paga sale más caro que revisar a alguien que sí habría pagado. Por eso la exactitud no sirve como métrica. Compararemos modelos con recall y precisión sobre la clase de impago, y el umbral de decisión se fijará según un costo por tipo de error. Esos costos serán supuestos nuestros y los declararemos como tales.

3. DATOS

Usaremos el conjunto Default of Credit Card Clients del repositorio UCI Machine Learning, donado por I-Cheng Yeh en 2016 con licencia CC BY 4.0. Reúne a 30,000 clientes de un banco de Taiwán y 23 variables explicativas: límite de crédito, datos demográficos, historial de pagos y montos de facturas y pagos entre abril y septiembre de 2005. La variable objetivo indica si el cliente cayó en impago al mes siguiente. El repositorio declara que no hay valores faltantes. Se descarga directo de la página y dejaremos la procedencia documentada en el cuaderno. Los impagos son una minoría, alrededor de 22 por ciento, algo que confirmaremos en el análisis exploratorio.

4. PLAN DE MODELADO

Partimos de una regresión logística regularizada, que es interpretable y fácil de justificar. Después la comparamos con un modelo basado en árboles, ya sea bosque aleatorio o gradient boosting. Los datos se dividen en entrenamiento, validación y prueba. Los hiperparámetros se ajustan con validación cruzada solo sobre entrenamiento, y el conjunto de prueba se toca una única vez. Evaluaremos con curva precisión-recall y costo esperado, y revisaremos dónde falla el modelo y para quiénes, por ejemplo por edad, sexo y nivel educativo.

5. RIESGO PRINCIPAL Y PLAN B

El riesgo mayor es que los datos son de 2005 y de un solo país, así que no presentaremos el modelo como válido para otro banco ni para otra época. También puede pasar que el desbalance deje al modelo con poco recall. El plan B es ajustar pesos por clase y el umbral por costo, y si eso no alcanza, probar remuestreo. En la presentación diremos con claridad qué no se puede concluir con estos datos.